비모수통계 및 실습 (326.414)

2주차 실습문제 풀이

Junseok Lee

March 12, 2026

안내 사항

- 실습문제는 과제문제랑 별개이며, **성적평가에 반영되지 않습니다.** 수강생분들의 학습에 도움이 되기 위해 만들었으며 자유롭게 활용하시면 됩니다.
- 실습시간에 문제를 해설하며, 솔루션은 eTL에 공개됩니다.

문제 1. (Sign Test)

표의 데이터는 시뮬레이션된 시험 점수이다. 강의 내용이 개정된 후 학기에 시험이 실시되었으며, 이전의 시험 점수 중앙값(median)은 70점이었다고 가정한다.

Table 1: 시뮬레이션된 시험 점수

65	66	71	72	74	74	74	74	74	74
75	76	76	76	76	76	76	76	77	77
77	78	78	79	80	80	80	80	81	81
84	84	85	85	86	86	87	87	88	96

중앙값(median)이 증가했는지 여부를 판정하고자 한다. 부호검정(sign test)을 적용하여 질문에 답하시오. 단측검정(one-sided test)을 사용하시오.

풀이. 중앙값을 θ, 귀무가설 하의 중앙값을 $\theta_0 = 70$이라 하자. 검정가설은

$$H_0 : \theta = 70 \qquad \text{vs.} \qquad H_1 : \theta > 70$$

이다.

부호검정에서

$$\psi(x) = \begin{cases} 1, & x > 0, \\ 0, & x \leq 0 \end{cases}$$

로 두면, 검정통계량은

$$B = \sum_{i=1}^{40} \psi(X_i - \theta_0) = \sum_{i=1}^{40} \psi(X_i - 70)$$

이다.

자료에서 70보다 큰 값은 38개이고, 70과 같은 값은 없으므로

$$B = 38.$$

귀무가설 H_0 하에서

$$B \sim \text{Bin}(40, 0.5),$$

따라서 대표본에서는 정규근사에 의해

$$B \approx N\left(\frac{40}{2}, \frac{40}{4}\right) = N(20,\, 10).$$

그러므로 표준화 통계량은

$$Z_B = \frac{B - \frac{n}{2}}{\sqrt{n/4}} = \frac{38 - 20}{\sqrt{10}} \approx 5.69$$

이다.

따라서 단측검정의 p-value는

$$p\text{-value} = P(Z \geq 5.69) \approx 0.$$

즉, 유의수준 0.05에서 귀무가설 H_0를 기각한다. 따라서 시험 점수의 중앙값은 70보다 증가하였다고 볼 수 있다.

문제 2. (Sign Test)

국세청(IRS)은 30명의 개인이 1040 세금 양식을 작성하는 데 걸리는 시간(분)을 기록하였다. IRS는 세금 양식을 작성하는 시간의 중앙값(median)이 160분이라고 주장한다.

Table 2: 세금 양식을 작성하는 데 걸리는 시간(분)

17	19	23	49	67	92	93	96	113	115
116	120	126	145	157	171	181	189	203	240
250	253	264	315	362	422	457	490	525	612

한 연구자는 양식을 작성하는 시간의 중앙값(median)이 160분을 초과한다고 믿는다. 연구자가 IRS의 주장에 반박할 수 있는지 판단하시오. 부호검정(sign test)을 적용하여 질문에 답하시오.

풀이. 가설은

$$H_0 : \theta = 160 \qquad \text{vs.} \qquad H_1 : \theta > 160$$

이다.

부호검정 통계량을

$$B = \sum_{i=1}^{30} \psi(X_i > 160)$$

라 두면, 160보다 큰 관측값은

$$171, 181, 189, 203, 240, 250, 253, 264, 315, 362, 422, 457, 490, 525, 612$$

의 15개이므로

$$B = 15.$$

귀무가설 하에서는

$$B \sim \text{Bin}(30, 0.5).$$

따라서 p-value는

$$p\text{-value} = P(B \geq 15) = \sum_{k=15}^{30} \binom{30}{k} (0.5)^{30} \approx 0.5722.$$

따라서 유의수준 5%에서 H_0를 기각할 수 없다. 즉, 연구자는 IRS의 주장을 반박할 수 없다.

문제 3. (비모수적 통계량의 수학적 성질)

다음은 크기가 N인 유한 모집단(finite population)에서 비복원 추출(without replacement)로 뽑은 크기 m인 확률표본(random sample) 합의 분산(variance)을 유도하는 과정이다. 모집단의 수치를 $A_1, A_2, \ldots, A_N$으로 표기하며, 수치 중 일부는 같을 수 있다. $X_1, X_2, \ldots, X_m$을 이 모집단에서 비복원 추출로 뽑은 크기 m인 확률표본이라 하고, $n = N - m$이라고 하자.

$T = \sum_{i=1}^{m} X_i$라고 할 때, 다음 성질들을 증명하시오:

(a) 임의의 추출에서 항목 A_i가 선택될 확률이 $1/N$임에 유의하시오. 따라서 기대값(expectation)은 $E(X_i) = \sum A_i/N$으로 주어진다. 이 사실을 이용하여 $E(T) = m\mu$임을 증명하시오.

(b) $E(X_i) = \sum A_i/N$ 외에, $E(X_i^2) = \sum A_i^2/N$임이 알려져 있다. 분산의 정의를 이용하여 $var(X_i) = E(X_i^2) - E(X_i)^2 = \sum_{i=1}^{N}(A_i - \mu)^2/N = \sigma^2$임을 증명하시오.

(c) 항목 A_i가 먼저 선택되고 A_j가 나중에 선택될 확률이 $1/\{N(N-1)\}$이다. 이때 $i \neq j$에 대하여, $E[(X_i - \mu)(X_j - \mu)] = \frac{1}{N(N-1)} \sum_{i \neq j}(A_i - \mu)(A_j - \mu)$라는 사실이 성립한다. 이를 이용하여 $i \neq j$일 때, 공분산 $cov(X_i, X_j) = E[(X_i - \mu)(X_j - \mu)] = -\frac{1}{N-1}\sigma^2$임을 증명하시오.

(d) 성질 $var(T) = \sum_{i=1}^{m} var(X_i) + \sum_{i \neq j} cov(X_i, X_j)$를 이용하여 $var(T) = \frac{mn}{N-1}\sigma^2$임을 증명하시오.

풀이.

(a) 모집단 평균을

$$\mu = \frac{1}{N}\sum_{j=1}^{N} A_j$$

라 하자. 각 X_i는 모집단 원소를 동일확률 $1/N$로 취하므로

$$E(X_i) = \frac{1}{N}\sum_{j=1}^{N} A_j = \mu.$$

따라서 기대값의 선형성에 의해

$$E(T) = E\left(\sum_{i=1}^{m} X_i\right) = \sum_{i=1}^{m} E(X_i) = m\mu.$$

(b)

$$\mathrm{Var}(X_i) = E(X_i^2) - \{E(X_i)\}^2 = \frac{1}{N}\sum_{j=1}^{N} A_j^2 - \mu^2.$$

한편

$$\frac{1}{N}\sum_{j=1}^{N}(A_j - \mu)^2 = \frac{1}{N}\sum_{j=1}^{N} A_j^2 - 2\mu\frac{1}{N}\sum_{j=1}^{N} A_j + \mu^2 = \frac{1}{N}\sum_{j=1}^{N} A_j^2 - \mu^2.$$

따라서

$$\mathrm{Var}(X_i) = \sigma^2.$$

(c) $i \neq j$일 때

$$E[(X_i - \mu)(X_j - \mu)] = \frac{1}{N(N-1)}\sum_{i \neq j}(A_i - \mu)(A_j - \mu).$$

그런데

$$\sum_{i=1}^{N}(A_i - \mu) = 0$$

이므로

$$0 = \left(\sum_{i=1}^{N}(A_i - \mu)\right)^2 = \sum_{i=1}^{N}(A_i - \mu)^2 + \sum_{i \neq j}(A_i - \mu)(A_j - \mu).$$

따라서

$$\sum_{i \neq j}(A_i - \mu)(A_j - \mu) = -\sum_{i=1}^{N}(A_i - \mu)^2 = -N\sigma^2.$$

그러므로

$$\mathrm{Cov}(X_i, X_j) = E[(X_i - \mu)(X_j - \mu)] = \frac{-N\sigma^2}{N(N-1)} = -\frac{\sigma^2}{N-1}.$$

(d)

$$\mathrm{Var}(T) = \sum_{i=1}^{m}\mathrm{Var}(X_i) + \sum_{i \neq j}\mathrm{Cov}(X_i, X_j).$$

위 결과를 대입하면

$$\mathrm{Var}(T) = m\sigma^2 + m(m-1)\left(-\frac{\sigma^2}{N-1}\right).$$

정리하면

$$\mathrm{Var}(T) = m\sigma^2\left(1 - \frac{m-1}{N-1}\right) = m\sigma^2\frac{N-m}{N-1}.$$

이제 $n = N - m$이므로

$$\mathrm{Var}(T) = \frac{mn}{N-1}\sigma^2.$$

문제 4. (동점이 있는 경우의 Wilcoxon Rank-Sum Test)

Wilcoxon rank-sum 검정통계량 W_1을 생각하자. 동점이 없는 경우, 대표본 근사에서

$$E[W_1] = \frac{m(N+1)}{2}, \qquad \mathrm{Var}(W_1) = \frac{mn(N+1)}{12}$$

이다.

동점이 있는 경우에는 W_{ties}를 계산하기 위해 약간의 수정이 필요하다. g를 동점 집단(tied groups)의 개수라 하고, t_j를 j번째 동점 집단의 크기라고 하자. 또한, 동점이 없는 관측값도 크기가 1인 하나의 "동점 집단"으로 간주한다. 예를 들어, $\{4, 4, 4, 5, 5, 6\}$은

$$g = 3, \qquad t_1 = 3,\ t_2 = 2,\ t_3 = 1$$

로 요약된다.

(a) 같은 m과 n에 대하여

$$E[W_{\text{ties}}] = E[W_1]$$

임을 보여라.

(b) 같은 m과 n에 대하여

$$\mathrm{Var}(W_{\text{ties}}) = \mathrm{Var}(W_1) - \frac{mn\sum_{j=1}^{g}(t_j^3 - t_j)}{12N(N-1)}$$

임을 보여라.

Hint. 크기가 t_j인 하나의 tied group이 연속된 순위

$$r,\ r+1,\ \ldots,\ r+t_j-1$$

를 차지한다고 하자. 이 그룹의 평균순위(average rank)를 $\bar{r}_j$라 하면

$$\bar{r}_j = \frac{r+(r+t_j-1)}{2} = r + \frac{t_j-1}{2}.$$

이때

$$t_j\bar{r}_j^2 = \sum_{k=r}^{r+t_j-1} k^2 - \sum_{k=r}^{r+t_j-1} (k-\bar{r}_j)^2$$

를 이용할 수 있다. 또한

$$\sum_{k=r}^{r+t_j-1} (k-\bar{r}_j)^2 = \frac{t_j^3-t_j}{12}$$

를 사용할 수 있다.

풀이. 전체 표본 크기를 $N=m+n$이라 하자. tie가 없을 때의 rank를

$$A_1=1,\ A_2=2,\ \ldots,\ A_N=N$$

이라 하자.

또한 지시변수 Z_i를

$$Z_i = \begin{cases} 1, & \text{if } A_i \text{ is selected in sample group 1,} \\ 0, & \text{if not} \end{cases}$$

로 정의하자. 그러면

$$W_1 = \sum_{i=1}^{N} A_i Z_i.$$

이제 tie가 있을 때의 rank를

$$A_1^*, A_2^*, \ldots, A_N^*$$

라 하자. 그러면

$$W_{\text{ties}} = \sum_{i=1}^{N} A_i^* Z_i$$

이다.

또한 tie group의 크기를 $t_1,\ldots,t_g$라 하면,

$$A_1^* = \cdots = A_{t_1}^* = \frac{1+\cdots+t_1}{t_1},$$

$$A_{t_1+1}^* = \cdots = A_{t_1+t_2}^* = \frac{(t_1+1)+\cdots+(t_1+t_2)}{t_2},$$

$$\cdots$$

$$A_{t_1+\cdots+t_{g-1}+1}^* = \cdots = A_{t_1+\cdots+t_g}^* = \frac{(t_1+\cdots+t_{g-1}+1)+\cdots+(t_1+\cdots+t_g)}{t_g}.$$

(a) 먼저

$$\sum_{i=1}^{N} A_i^* = (1+\cdots+t_1)+\big((t_1+1)+\cdots+(t_1+t_2)\big)+\cdots+\big((t_1+\cdots+t_{g-1}+1)+\cdots+(t_1+\cdots+t_g)\big)$$

이므로

$$\sum_{i=1}^{N} A_i^* = \sum_{i=1}^{N} i = \frac{N(N+1)}{2}.$$

한편 각 i에 대하여

$$E(Z_i) = P(Z_i = 1) = \frac{m}{N}.$$

따라서

$$E(W_{\text{ties}}) = E\left(\sum_{i=1}^{N} A_i^* Z_i\right) = \sum_{i=1}^{N} A_i^* E(Z_i) = \frac{m}{N}\sum_{i=1}^{N} A_i^* = \frac{m}{N}\cdot\frac{N(N+1)}{2} = \frac{m(N+1)}{2}.$$

즉,

$$E(W_{\text{ties}}) = E(W_1).$$

(b) 먼저

$$E(Z_i) = \frac{m}{N}, \qquad E(Z_i^2) = E(Z_i) = \frac{m}{N}$$

이므로

$$\mathrm{Var}(Z_i) = E(Z_i^2) - \{E(Z_i)\}^2 = \frac{m}{N}\left(1-\frac{m}{N}\right) = \frac{mn}{N^2}.$$

또한 $i \neq j$에 대하여

$$E(Z_iZ_j) = 1\cdot P(Z_i = 1, Z_j = 1) = \frac{m}{N}\cdot\frac{m-1}{N-1},$$

따라서

$$\mathrm{Cov}(Z_i, Z_j) = E(Z_iZ_j) - E(Z_i)E(Z_j) = \frac{m(m-1)}{N(N-1)} - \frac{m^2}{N^2} = -\frac{mn}{N^2(N-1)}.$$

이제

$$\mathrm{Var}(W_{\text{ties}}) = \mathrm{Var}\left(\sum_{i=1}^{N} A_i^* Z_i\right)$$

이므로

$$\mathrm{Var}(W_{\text{ties}}) = \sum_{i=1}^{N}(A_i^*)^2\mathrm{Var}(Z_i) + \sum_{i\neq j} A_i^* A_j^* \mathrm{Cov}(Z_i, Z_j).$$

위 결과를 대입하면

$$\mathrm{Var}(W_{\text{ties}}) = \frac{mn}{N^2}\sum_{i=1}^{N}(A_i^*)^2 - \frac{mn}{N^2(N-1)}\sum_{i\neq j} A_i^* A_j^*.$$

그리고

$$\sum_{i\neq j} A_i^* A_j^* = \left(\sum_{i=1}^{N} A_i^*\right)^2 - \sum_{i=1}^{N}(A_i^*)^2$$

이므로

$$\mathrm{Var}(W_{\text{ties}}) = \frac{mn}{N^2(N-1)}\left\{N\sum_{i=1}^{N}(A_i^*)^2 - \left(\sum_{i=1}^{N}A_i^*\right)^2\right\}.$$

이제 $\sum_{i=1}^{N}(A_i^*)^2$를 계산하자. 크기가 t_j인 tie group 하나를 생각하면, 그 group의 평균순위를 $\bar{r}_j$라 할 때

$$\sum_{k=r}^{r+t_j-1} k^2 - t_j\bar{r}_j^2 = \frac{t_j^3 - t_j}{12}$$

이다. 따라서 각 tie group에 대해

$$t_j\bar{r}_j^2 = \sum_{k=r}^{r+t_j-1} k^2 - \frac{t_j^3 - t_j}{12}.$$

이를 모든 group에 대해 합하면

$$\sum_{i=1}^{N}(A_i^*)^2 = \sum_{i=1}^{N}A_i^2 - \sum_{j=1}^{g}\frac{t_j^3 - t_j}{12}.$$

또

$$\sum_{i=1}^{N}A_i^* = \sum_{i=1}^{N}A_i$$

이므로

$$\mathrm{Var}(W_{\text{ties}}) = \frac{mn}{N^2(N-1)}\left\{N\left(\sum_{i=1}^{N}A_i^2 - \sum_{j=1}^{g}\frac{t_j^3 - t_j}{12}\right) - \left(\sum_{i=1}^{N}A_i\right)^2\right\}.$$

즉,

$$\mathrm{Var}(W_{\text{ties}}) = \frac{mn}{N^2(N-1)}\left\{N\sum_{i=1}^{N}A_i^2 - \left(\sum_{i=1}^{N}A_i\right)^2\right\} - \frac{mn}{12N(N-1)}\sum_{j=1}^{g}(t_j^3 - t_j).$$

그런데 첫 번째 항은 tie가 없을 때의 분산, 즉 $\mathrm{Var}(W_1)$이므로

$$\mathrm{Var}(W_{\text{ties}}) = \mathrm{Var}(W_1) - \frac{mn}{12N(N-1)}\sum_{j=1}^{g}(t_j^3 - t_j).$$

따라서

$$\mathrm{Var}(W_{\text{ties}}) = \mathrm{Var}(W_1) - \frac{mn\sum_{j=1}^{g}(t_j^3 - t_j)}{12N(N-1)}.$$